

第 1 章 时间序列

1.1 认识时间序列

定义 1.1 (时间序列)

时间序列中的每个特殊点都与先前的数据点相关。



人们通常使用一些简单的预测法：

1.1.1 朴素预测法

定理 1.1

朴素预测法是时间序列预测中最简单的一种方法，它假设未来的值等于最近一个观测值。

$$\hat{y}_{t+1} = y_t \quad (1.1)$$

其中， $\hat{y}_{t+1}$ 是对下一个时间点的预测值， y_t 是当前时间点的实际观测值。



1.1.2 简单平均值法

定理 1.2 (简单平均值法)

简单平均值法是通过计算历史数据的平均值来预测未来的值。

$$\hat{y}_{t+1} = \frac{1}{n} \sum_{i=1}^n y_i \quad (1.2)$$

其中， n 是历史数据点的数量， y_i 是第 i 个观测值。



它将下一个值视为先前所有值的平均数，但是这个方法的值可能并不都有用。

💡 Tips

因为可能你要预测今天的温度，只需要考虑七天内的温度即可，而不是一个月内的温度。

1.1.3 移动平均法

为了解决上面这个方案的不足，移动平均法就诞生了。

定理 1.3 (移动平均法)

移动平均法是通过计算最近 n 个观测值的平均值来预测未来的值。

$$\hat{y}_{t+1} = \frac{1}{n} \sum_{i=0}^{n-1} y_{t-i} \quad (1.3)$$

其中， y_{t-i} 是当前时间点 t 向前推 i 个时间点的观测值。



1.1.4 加权移动平均法

定理 1.4 (加权移动平均法)

加权移动平均法是对最近 n 个观测值赋予不同的权重来预测未来的值。

$$\hat{y}_{t+1} = \sum_{i=0}^{n-1} w_i y_{t-i} \quad (1.4)$$

其中， w_i 是第 i 个观测值的权重，满足 $\sum_{i=0}^{n-1} w_i = 1$ 。



1.1.5 简单指数平滑法

定理 1.5 (简单指数平滑法)

更大的权重被分配给更近期的观测结果，遥远的过去的观测值被赋予更小的权重。



1.1.6 霍尔特线性趋势模型

定理 1.6 (霍尔特线性趋势模型)

这个方法考虑了数据集的趋势。例如是递增或递减的，这个方法的预测函数是值和趋势的函数。



1.1.7 霍尔特-温特斯 (Holt Winters) 方法


定理 1.7

该算法考虑了数据的趋势和季节性变化，例如酒店在周末订单数量更多，在工作日就会很低。



1.2 ARIMA 模型

ARIMA 时间序列建模流程



定义 1.2 (ARIMA 模型)

ARIMA 的全称是自回归整合移动平均模型 (AutoRegressive Integrated Moving Average)，它是一种用于时间序列预测的统计模型。它有三个部分：

1. AR (自回归)：模型中包含数据过去的值。参数 p 是自回归的阶数（这个参数由 PACF 图确定）。实际上，就是由一个基准值，确定了某些线性系数后，参考过去的值得到现在的值，即下述公式（线性模型一定存在误差 ε_t ）：

$$y_t = \mu + \sum_{i=1}^p r_i \cdot y_{t-i} + \varepsilon_t$$

2. I (整合/差分)：为了让数据变得平稳而进行的差分次数。参数 d 是差分的阶数。
3. MA (移动平均)：为了解决线性模型中的误差，MA 就产生了，模型中包含了过去的预测误差。参数 q 是移动平均的阶数（由 ACF 图确定）。将前面的预测产生的误差进行叠加，即：

$$y_t - 4y_{t-3}y_{t-2}y_{t-1} + \sum \theta_i \varepsilon_i = y_t$$

4. 合体之后，就是 ARMA 模型：

$$y_t = \mu + \sum_{i=1}^p \gamma_i y_{t-i} + \sum_{i=1}^q \theta_i \varepsilon_{t-i}$$

5. 所以，建立一个 ARIMA 模型，我们最终需要确定 (p, d, q) 这三个参数。



ARIMA 模型的执行流程可以分为以下几个步骤：

1. 数据准备：创建一组有趋势和季节性的模拟时间序列数据。
2. 平稳性检验：通过可视化和统计检验（ADF 检验）判断序列是否平稳。

- 差分处理：对非平稳序列进行差分，使其平稳，并确定差分阶数 d 。
- 模型定阶：使用 ACF 和 PACF 图来帮助确定 p (自回归阶数) 和 q (移动平均阶数)。
- 模型训练与预测：建立并训练 ARIMA 模型，然后进行预测。
- 结果可视化：将预测结果与真实值进行对比。
- 计算 RMSE：这个值越大，模型的性能就越好。

1.2.1 ARIMA 模型的执行步骤

1.2.1.1 平稳性检验

拿到一个时间序列首先需要平稳性检验和白噪声检验（随机性检验），只有处理为平稳的非白噪声数据才能继续使用 ARIMA 模型进行预测。

```
1 ds = [10930, 10318, 10595, 10972, 7706, 6756, 9092, 10551, 9722, 10913, 11151, 8186, 6422,
2       6337, 11649, 11652, 10310, 12043, 7937, 6476, 9662, 9570, 9981, 9331, 9449, 6773, 6304, 9355,
3       10477, 10148, 10395, 11261, 8713, 7299, 10424, 10795, 11069, 11602, 11427, 9095, 7707, 10767,
4       12136, 12812, 12006, 12528, 10329, 7818, 11719, 11683, 12603, 11495, 13670, 11337, 10232,
5       13261, 13230, 15535, 16837, 19598, 14823, 11622, 19391, 18177, 19994, 14723, 15694, 13248,
6       9543, 12872, 13101, 15053, 12619, 13749, 10228, 9725, 14729, 12518, 14564, 15085, 14722,
7       11999, 9390, 13481, 14795, 15845, 15271, 14686, 11054, 10395]
8
9 # 原 Data Series
10 ds = pd.Series(ds)
11 ds.index = pd.Index(sm.tsa.datetools.dates_from_range('2001', '2090'))
12 ds.plot(figsize=(12, 8))
13 plt.title('dta')
```

1.2.1.2 差分处理

均值和方差差不多不变的，就算是平稳的。ARIMA 模型只能预测平稳的。若不平稳，就进行 n 阶差分。

```
1 dta_diff1 = ds.diff(1)
2 dta_diff1.dropna(inplace=True)
```

1.2.1.3 ADF 平稳性检验

- 要检验当前的数据序列是否平稳，除了观察趋势、季节性、方差变化之外，还可以通过单位根检验，在 ARIMA 模型中，通常使用 **ADF** 检验。

定理 1.8 (ADF 检验)

- 原假设 H_0 ：时间序列存在单位根（非平稳）。
- 备择假设 H_1 ：时间序列不存在单位根（平稳）。
- 通过计算 ADF 统计量并与临界值比较来进行检验。

1. P 值若 ≤ 0.05 （或自己选择更小的），则有充分的理由拒绝原假设，认为序列是平稳的。

2. 如果 $P > 0.05$ ，则我们不能拒绝原假设，认为序列是非平稳的。

3. ADF Test Statistic（ADF 检验统计量）：

- 这是一个负数。如果这个值越小（越负），就越有理由拒绝原假设，认为数据是平稳的。
- 需要将它与不同显著性水平下的 Critical Values（临界值）进行比较。如果 Test Statistic $<$ Critical Value，则拒绝原假设，认为序列是平稳的。

💡 Tips

在 Python 中使用 ADF 检验，可以使用 `adfuller` 函数。

```
1 def test_stationarity(timeseries):
2     # 计算滚动均值
3     roll_mean = timeseries.rolling(20).mean()
```

```

4 roll_std = timeseries.rolling(20).std()
5
6 plt.figure(figsize=(10, 5))
7 plt.plot(timeseries, color='blue', label='原序列')
8 plt.plot(roll_mean, color='red', label='滚动均值')
9 plt.plot(roll_std, color='black', label='滚动标准差')
10 plt.legend(loc='best')
11 plt.title('Rolling Mean & Standard Deviation')
12 plt.show()
13
14 # Perform Augmented-Dickey-Fuller Test:
15 res = adfuller(timeseries, autolag='AIC') # 使用 AIC 准则选择滞后阶数
16 print(f"ADF Value: {res[0]:.4f}, P: {res[1]:.8f}")
17 for k, v in res[4].items():
18     print('Critical Values:')
19     print(f'    {k}, {v:.3f}')
20 return res

```

此处，我们从 `adfuller` 中获取 ADF 的值以及 Critical Value，ADF 值应该比 Critical Values 都小。

```

1 ADF Value: -4.9939, P: 0.00002282
2 Critical Values:
3     1%, -3.519
4 Critical Values:
5     5%, -2.900
6 Critical Values:
7    10%, -2.587


```

1.2.1.4 选择最佳的 p 和 q 参数

完成上述步骤，我们就可以选择最佳的 p 和 q 参数的值了。此时需要获取平稳时间序列的自相关图和偏自相关图。

定义 1.3 (截尾和拖尾)

- 截尾：在大于某个常数后，快速地趋近于 0，则为 k 阶截尾
- 拖尾：始终有非零值，不会在 k 大于某个常数后就恒等于 0



模型	自相关系数 (ACF)	偏自相关系数 (PACF)
AR (p)	拖尾	P 阶截尾
MA (q)	q 阶截尾	拖尾
ARMA (p, q)	p 阶拖尾	q 阶拖尾

图 1.1: ARMA 模式识别原则

若是双截尾，则序列本身不存在明显的自相关性，ARMA 类模型可能不适用。



Warning

这个图的读数法，置信区间是蓝色的部分，观察 PACF 图和 ACF 图呈现的是关系，从而确定符合什么模型，例如上图，两个都是拖尾，数据就可能符合 $ARMA(p, q)$ 模型，但是这种情况下，从图形中很难判断 p 和 q 的精确值。

Tips

当然，如果是比较简单的：

- 如果 PACF 图呈现“截尾”，ACF 图呈现“拖尾”：强烈暗示数据符合 $AR(p)$ 模型。数出 PACF 图在哪一阶“截断”。例如，如果 PACF 在第 2 阶之后的所有值都落入置信区间，那么 p 值就取 2。模型可以定为 $ARIMA(2, d, 0)$ 。
- 如果 ACF 图呈现“截尾”，PACF 图呈现“拖尾”：数据符合 $MA(q)$ 模型。数出 ACF 图在哪一阶“截断”。例如，如果 ACF 在第 1 阶之后的所有值都落入置信区间，那么 q 值就取 1。模型可以定为 $ARIMA(0, d, 1)$ 。



1.2.1.5 信息准则定阶

参考文献: <https://www.cnblogs.com/iupoint/p/14621830.html>

信息准则的好处是，在模型给出预测之前，就能对模型的超参做一个量化评估。

在批量预测的场景中尤其有用。因为批量预测往往需要程序在执行过程中自动确定阶数。

定义 1.4 (AIC 赤池信息准则)

$$AIC = -2\ln(L) + 2(p + q + k + 1)$$

其中, L 是模型的似然函数, p 是自回归阶数, q 是移动平均阶数, k 是模型中参数的个数。 $k = 1$ 表示模型考虑常数 c , $k = 0$ 表示不考虑。最后一个 1 表示算上误差项, 所以第二项实际上就是 $2 \times$ 参数个数。

而修正过的 AIC_c 更好:

$$AIC_c = AIC + \frac{2(p + q + k + 1)(p + q + k + 2)}{T - p - q - k - 2}$$



定义 1.5 (BIC 贝叶斯信息准则)

$$BIC = AIC + [\ln(T) - 2](p + q + k + 1)$$



定理 1.9

信息准则越小, 说明参数的选择越好, 一般就采用 AIC_c 或者 BIC 。



差分量 d 不要使用信息准则来判断, 因为差分后会改变似然函数所使用的数据, 信息的准则比较就失去了意义, 所以先用其他的方法算出 d 。 **Warning**


注意, AIC 和 BIC 信息量准则必须在原始数据上进行应用, 所有参与比较的模型, 必须是对完全相同的观测数据计算出的似然函数 L 。 **Warning**

并且, 这里会构造一个 $ARIMA(p, d, q)$ 模型, 已经具备差分了。

```
1 # 我们将行设置为 p (AR), 列设置为 q (MA)
2 aic_matrix = pd.DataFrame(index=[f'AR{i}' for i in range(p_max + 1)],
3                             columns=[f'MA{i}' for i in range(q_max + 1)],
4                             dtype=float)
5 bic_matrix = pd.DataFrame(index=[f'AR{i}' for i in range(p_max + 1)],
6                             columns=[f'MA{i}' for i in range(q_max + 1)],
7                             dtype=float)
8
9 for p in range(p_max + 1):
10     for q in range(q_max + 1):
11         # 避免拟合 ARIMA(0, 1, 0) 模型
12         if p == 0 and q == 0:
13             continue
14
15         # 注意: 我们是在原始序列 ds 上操作, 并设置 d=1
16         model = sm.tsa.ARIMA(ds, order=(p, 1, q))
17         results = model.fit()
18
19         # 将AIC和BIC存储到矩阵中
20         aic_matrix.iloc[p, q] = results.aic
21         bic_matrix.iloc[p, q] = results.bic
22         print(f'完成: ARIMA({p}, 1, {q}) - AIC:{results.aic:.2f}, BIC:{results.bic:.2f}')
```

我们可以接着绘制 BIC 信息量的 HeatMap, 这样能够可视化选取最优模型:

```
1 plt.figure(figsize=(10, 8))
2 sns.heatmap(bic_matrix.astype(float), annot=True, fmt=".2f", cmap="Purples")
3 plt.title('BIC (Bayesian Information Criterion) Heatmap')
4 plt.xlabel('MA order (q)')
5 plt.ylabel('AR order (p)')
6 plt.show()
```



由图可知，我们可以选取 MA6,AR6 模型进行 ARIMA 预测。这个 BIC 值是最小的。（BIC 值也可能是负值）

1.2.1.6 模型初步构建

```
1 # 构建 ARIMA 模型
2 model = sm.tsa.ARIMA(ds, order=(6,1,6))
3 results = model.fit()
4 pprint(results.summary())
```

这里的 Summary 结果可以为我们提供精简的信息。

1.2.1.7 SARIMA 季节性周期模型

如果后续发现有季节性周期变化，可以使用 SARIMA 模型。

```
1 # 使用 SARIMA 季节性模型
2 sarima_model = sm.tsa.SARIMAX(ds,order=(6, 1, 6),seasonal_order=(6, 1, 6, 7))
3 sarima_results = sarima_model.fit()
4 print(sarima_results.summary())
```

1.2.1.8 模型检验

定义 1.6 (QQ 图)

QQ 图用于直观验证一组数据是否来自某个分布，或者验证某两组数据是否来自同一（族）分布。

QQ 图是一种散点图，对应于正态分布的 QQ 图，就是由标准正态分布的分位数为横坐标，样本值为纵坐标的散点图。若 QQ 图上的点近似地在一条直线附近，说明是正态分布，而且该直线的斜率为标准差，截距为均值，用 QQ 图还可获得样本偏度和峰度的粗略信息。

定义 1.7 (Ljung-Box 检验)

判断模型的残差序列是否是白噪声（即完全随机，不存在任何自相关性）。一个好的模型，其残差必须是白噪声。LB 检验则是基于一系列滞后阶数，判断序列总体的相关性或者说随机性是否存在。

1. 原假设 (H_0): 残差是白噪声。
2. 我们希望得到的结果是无法拒绝原假设，即希望 $P > 0.05$ 。

```
1 Ljung-Box Test on Residuals:
2 lb_stat lb_pvalue
3 1 0.069148 0.792582
```



```


4 2 1.175858 0.555477
5 3 1.940543 0.584838
6 4 3.707892 0.446979
7 5 7.766225 0.169599
8 6 7.968889 0.240391
9 7 10.378889 0.168099
10 8 10.569353 0.227314
11 9 10.589831 0.304874
12 10 10.772259 0.375534
13 11 11.086204 0.436070
14 12 11.159994 0.515259

```

当所有的 P 值都远远 > 0.05 时，说明模型残差是纯粹的白噪声，模型已经成功提取了原始数据中所有的自相关（包括季节性）信息，没有任何规律被遗漏。

定义 1.8 (D-W 检验)

D-W 值显著接近于 0 或 4 时，则存在自相关性，而接近于 2 时，则不存在（一阶）自相关性。



在构建完一个时间序列模型（如 ARIMA 或 SARIMA）后，我们必须对其进行模型诊断。

残差是模型的预测值与真实值之间的误差。一个好的模型，其残差序列应该表现为白噪声，即：

- 均值为 0，方差恒定（稳定性）。
- 不存在自相关性（独立性）。
- 服从正态分布（正态性）。

`statsmodels` 库提供的标准四联诊断图正是围绕这几个核心假设进行检验的。

左上角：标准化残差图

观察残差随时间的变化情况，用于直观判断残差序列是否稳定，是否存在异方差。

- **理想情况：**残差序列应在均值 0 的水平线上下随机、均匀地波动，没有显示出任何明显的趋势或周期性模式。同时，波动的幅度（方差）应该大致保持恒定。
- **问题情况：**
 - 存在明显的上升或下降趋势、明显的周期性波动。
 - 出现异方差性，例如波动的幅度随时间推移逐渐增大（呈喇叭口形状）或减小。

右上角：直方图与核密度估计图

检验残差的分布形态是否接近于正态分布。图中包含三条信息：

- **蓝色直方图**: 残差数据的频数分布。
- **橙色 KDE 曲线**: 根据残差数据估计出的实际概率密度分布。
- **绿色 $N(0,1)$ 曲线**: 标准正态分布的理论概率密度曲线。
- **理想情况**: 橙色 KDE 曲线与绿色 $N(0,1)$ 曲线应高度重合，且蓝色直方图的轮廓呈现对称的“钟形”。
- **问题情况**: 橙色曲线与绿色曲线形状差异巨大，或者直方图呈现明显的左偏或右偏形态。

左下角：正态 Q-Q 图

通过比较残差的分位数与正态分布的分位数，更严谨地检验其正态性。

- **理想情况**: 图中的蓝色数据点应基本紧密地排列在红色的对角线上。
- **问题情况**: 数据点系统性地偏离红线，形成“S”形、“弓”形或其他弯曲模式。
 - **“肥尾” (Fat tails)**: 两端点向上和向下偏离红线，说明真实分布的尾部比正态分布更厚，存在更多极端值。
 - **“瘦尾” (Thin tails)**: 两端点向红线内侧偏离。

右下角：相关图 ACF

检验残差中是否存在自相关性，这是判断残差是否为白噪声的最关键指标之一。

- **理想情况**: 除了滞后阶数为 0 时（其值恒为 1），其他所有滞后阶数的垂直线都应该落在蓝色的置信区间以内。
- **问题情况**: 有一根或多根垂直线显著地超出了蓝色置信区间的边界。这说明在对应的滞后阶数上存在显著的自相关，模型未能完全捕捉数据中的信息。

1.2.2 ARIMA 模型的特例

定义 1.9 (特例)

1. $ARIMA(0, 1, 0)$: (此时当 $d = 1, p$ 和 q 为 0 时，称为 Random Walk 模型)，该模型表示每一个时刻的位置，只与上一时刻的位置有关。
2. $ARIMA(1, 0, 0)$: (此时 $p = 1, d = 0, q = 0$ ，称为 First-order Autoregressive Model)，该模型说明时序数据是稳定的和自相关的。
3. $ARIMA(1, 1, 0)$: (此时 $p = 1, d = 1, q = 0$ ，称为 Differenced First-order Autoregressive Model)，该模型说明时序数据在一阶差分化之后是稳定的和自回归的，即一个时刻的差分 (y) 只与上一个时刻的差分有关。
4. $ARIMA(0, 1, 1)$: (此时 $p = 0, d = 1, q = 1$ ，称为 Simple Exponential Smoothing With Growth 模型)，该模型说明数据在一阶差分后是稳定的和移动平均的，即一个时刻的估计值的差分与上一个时刻的预测误差有关。

