

第 1 章 主成分分析

1.1 PCA 主成分分析

定义 1.1 (主成分分析)

主成分分析可以用较少的新变量替换原来较多的新变量，而且是这些较少的新变量尽可能多地保留原来所反映的信息。主成分分析是数据降维算法的一种，降维是将高维度的数据（指标太多）保留下最重要的一些特征，去除噪声和不重要的特征。



- 主成分分析的困难在于要能够给出主成分的较好解释，所提取的主成分中如有一个主成分解释不了，整个主成分分析也就失败了。
- 主成分分析不可用于评价类模型。
- 主成分分析可用于聚类分析，将自变量进行降维方便画图。
- 主成分分析也可用于回归分析解决多重共线性的问题。

Warning

定理 1.1 (主成分分析的思想)

假设有 n 个样本， p 个指标，则可构成大小为 $n \times p$ 的样本矩阵 x ：

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} = (x_1, x_2, \cdots, x_p)$$

假设我们想找到新的一组变量 $z_1, z_2, \dots, z_m (m \leq p)$ ，且它们满足：

$$\begin{cases} z_1 = l_{11}x_1 + l_{12}x_2 + \cdots + l_{1p}x_p \\ z_2 = l_{21}x_1 + l_{22}x_2 + \cdots + l_{2p}x_p \\ \cdots \\ z_m = l_{m1}x_1 + l_{m2}x_2 + \cdots + l_{mp}x_p \end{cases}$$

系数 l_{ij} 的确定原则：

- z_i 与 $z_j (i \neq j; i, j = 1, 2, \dots, m)$ 相互无关；
- z_1 是 $x_1, x_2, \dots, x_p$ 的一切线性组合中方差最大者；
- z_2 是与 z_1 不相关的 $x_1, x_2, \dots, x_p$ 的所有线性组合中方差最大者；
- 以此类推， z_m 是与 $z_1, z_2, \dots, z_{m-1}$ 不相关的 $x_1, x_2, \dots, x_p$ 的所有线性组合中方差最大者；
- 新变量指标 $z_1, z_2, \dots, z_m$ 分别称为原变量指标 $x_1, x_2, \dots, x_p$ 的第一，第二， $\dots$ ，第 m 主成分。



1.1.1 PCA 降维的操作流程

并非所有的数据都适用于主成分分析的。主成分分析本身并不是目的，实际应用中主成分分析往往是一种手段。的是通过主成分分析简化数据结构，在此基础上进行进一步的分析。

Warning

主成分分析使用前，需要判断变量之间是否存在强相关性，或者说多重共线性，检测的方法有很多，例如：

- 相关性矩阵 (Correlation Matrix)
- KMO 检验 (Kaiser-Meyer-Olkin Test)
- Bartlett's 球形检验 (Bartlett's Test of Sphericity)
- 方差膨胀因子 (Variance Inflation Factor, VIF)

定义 1.2 (KMO 检验)

KMO 检验通过比较变量间的简单相关系数和偏相关系数，来检验数据的“纯度”。其核心思想是：如果变量之间存在共同的潜在因子（主成分），那么它们之间的简单相关性应该远大于偏相关性（即在控制了其他变量后，两个变量之间的

相关性应该很小)。KMO 统计量的计算公式为：

$$KMO = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} a_{ij}^2} \quad (1.1)$$

其中， r_{ij} 是变量 i 和 j 之间的简单相关系数， a_{ij} 是在控制了其他所有变量后，变量 i 和 j 之间的偏相关系数。

KMO 的取值范围在 0 到 1 之间。值越接近 1，说明变量间的共同因素越多，数据越适合进行主成分分析。

Kaiser (1974) 给出的判断标准如下：

KMO 值范围	0.90 以上	0.80-0.89	0.70-0.79	0.60-0.69	0.50-0.59	0.50 以下
适合程度	非常适合	很适合	适合	一般	不佳	不适合



定义 1.3 (Bartlett's 球形检验)

Bartlett's 检验是一种统计假设检验，用于判断相关性矩阵是否为一个单位矩阵（即对角线为 1，其余为 0）。如果相关性矩阵是单位矩阵，则说明所有变量都是相互独立的，不适合进行主成分分析。

我们进行假设：

- 原假设 (H_0): 相关性矩阵 $\mathbf{R}$ 是一个单位矩阵 ($\mathbf{R} = \mathbf{I}$)。
- 备择假设 (H_1): 相关性矩阵 $\mathbf{R}$ 不是一个单位矩阵。

检验统计量近似服从卡方 (χ^2) 分布，其计算公式为：

$$\chi^2 = - \left(n - 1 - \frac{2p+5}{6} \right) \ln(|\mathbf{R}|) \quad (1.2)$$

其中： n 是样本数量， p 是变量数量， $|\mathbf{R}|$ 是相关性矩阵 $\mathbf{R}$ 的行列式。该统计量的自由度为 $df = \frac{p(p-1)}{2}$ 。

计算出统计量后，我们可以得到一个对应的 p 值。如果 p 值非常小（例如 $p < 0.05$ ），我们就可以拒绝原假设 H_0 ，认为变量之间存在显著的相关性，因此数据适合进行主成分分析。

做因子分析时是一样的，如果该值较大，且其对应的相伴概率值小于用户心中的显著性水平，那么应该拒绝零假设，认为相关系数不可能是单位阵，即原始变量之间存在相关性，适合于作因子分析。相反不适宜作因子分析。

Tips



```
1 Compute the Bartlett sphericity test.
2 H0: The matrix of population correlations is equal to I. H1: The matrix of population correlations is not equal to I.
3 The formula for Bartlett's Sphericity test is:
4 -1*(n-1-((2p+5)/6))*ln(det(R))
5 Where R det(R) is the determinant of the correlation matrix, and p is the number of variables.
```

定义 1.4 (方差膨胀因子)

VIF 是衡量多重共线性严重程度的指标。虽然它常用于回归分析的诊断，但其原理可以直接用于判断 PCA 的适用性，因为它直接度量了一个变量在多大程度上能被其他变量所解释。对于第 j 个变量 X_j ，其 VIF 值的计算步骤如下：

1. 构建一个线性回归模型，其中 X_j 是因变量，所有其他 $p-1$ 个变量是自变量：

$$X_j = \beta_0 + \beta_1 X_1 + \cdots + \beta_{j-1} X_{j-1} + \beta_{j+1} X_{j+1} + \cdots + \beta_p X_p + \epsilon$$

2. 计算这个回归模型的决定系数 R_j^2 。 R_j^2 表示其他变量能解释 X_j 方差的比例。
3. 第 j 个变量的 VIF 值定义为：

$$VIF_j = \frac{1}{1 - R_j^2} \quad (1.3)$$

VIF 的值越大，说明变量 X_j 与其他变量的共线性越强。

- $VIF = 1$: 不存在多重共线性
- $1 < VIF < 5$: 存在一定的共线性，但通常可以接受
- $VIF \geq 5$ 或 10: 存在严重的共线性

在 PCA 的前置检验中，我们期望看到一些较大的 VIF 值，这恰恰说明了变量间存在冗余信息，可以通过 PCA 进行有效合并和降维。



以上检验均可以直接调库实现。

```
1 print("--- 1. 相关性矩阵检验 ---")
2 corr_matrix = df_features.corr()
3 plt.figure(figsize=(8, 6))
4 sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f")
5 plt.title('特征相关性矩阵热力图')
6 plt.show()
7
8 print("--- 2. KMO 检验 ---")
9 kmo_all, kmo_model = calculate_kmo(df_features)
10
11 print("--- 3. Bartlett's 球形检验 ---")
12 chi_square_value, p_value = calculate_bartlett_sphericity(df_features)
13
14 print("--- 4. 方差膨胀因子 (VIF) 检验 ---")
15 X_vif = sm.add_constant(df_features)
16 vif_data = pd.DataFrame()
17 vif_data["feature"] = X_vif.columns
18 vif_data["VIF"] = [variance_inflation_factor(X_vif.values, i) for i in range(X_vif.shape[1])]
```

表 1.1: 客户信用评级数据 (保留两位小数)

客户编号	能力	品格	担保	资本	环境
1	61.76	60.82	62.72	61.39	63.88
2	65.26	65.98	65.97	66.52	65.37
3	63.19	64.81	65.06	62.85	65.10
4	65.02	63.93	64.31	64.04	62.36
5	64.23	65.44	64.01	62.93	65.47
6	65.84	64.00	65.10	64.69	64.97
7	64.85	62.85	62.75	64.71	64.24
8	56.94	58.12	62.72	59.12	65.57
9	66.88	68.81	65.50	67.83	64.48
10	61.22	61.13	62.10	61.64	63.45
11	63.89	65.23	63.05	62.98	63.38
12	3.92	63.05	62.98	63.35	63.81

1.1.1.1 数据标准化

为了消除不同特征的量纲和数值范围的影响，首先需要对数据进行标准化。其计算公式如下：

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{S_j}, \quad \text{其中, } \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad S_j = \sqrt{\frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}{n-1}}$$

1.1.1.2 计算相关系数矩阵

计算标准化后的数据矩阵 $\mathbf{Z}$ 的相关系数矩阵 $\mathbf{R}$ 。(如果未进行标准化，则计算协方差矩阵 Σ)。再求解相关系数矩阵的特征值和特征向量：

$$\mathbf{R} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z}$$

求解满足以下方程的 λ 和 $\mathbf{w}$ ：

$$\mathbf{R}\mathbf{w} = \lambda\mathbf{w}$$

对于一个 $p \times p$ 的矩阵 $\mathbf{R}$ ，我们可以解出 p 个特征值 $\lambda_1, \lambda_2, \dots, \lambda_p$ 和与之对应的 p 个特征向量 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_p$ 。我们将特征值从大到小排序： $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ 。

- **特征值 (λ_i)**：代表了第 i 个主成分能够解释的方差大小。 λ_1 最大，第一主成分解释了最多的数据方差。

1.1.1.3 选择主成分

我们希望用 k 个主成分 ($k < p$) 来代替原来的 p 个特征。如何确定 k 的值？通常通过计算累计方差贡献率决定。则第 i 个主成分的方差贡献率为：

$$\text{Variance Explained}_i = \frac{\lambda_i}{\sum_{j=1}^p \lambda_j}$$

选择最小的 k 值，使得累计贡献率达到一个阈值（例如 85% 或 90%）：

$$\sum_{i=1}^k \frac{\lambda_i}{\sum_{j=1}^p \lambda_j} \geq \text{Threshold (e.g., 0.85)}$$

对于某个主成分而言，指标前面的系数越大，代表该指标对该主成分的影响越大。

💡 Tips

1.1.1.4 生成新的数据矩阵


选定了前 k 个主成分后，我们将这 k 个对应的特征向量 $\mathbf{w}_1, \dots, \mathbf{w}_k$ 按列组合成一个投影矩阵 W ：

$$W = \begin{pmatrix} \mathbf{w}_1 & \mathbf{w}_2 & \dots & \mathbf{w}_k \end{pmatrix}_{p \times k}$$

最后，将标准化后的原始数据矩阵 Z 投影到这个新的坐标系上，得到降维后的新数据矩阵 Y ：


$$Y = ZW$$

这个新的矩阵 Y 的维度是 $n \times k$ ，成功地将数据的特征从 p 维降到了 k 维。矩阵 Y 中的每一列就是一个主成分的得分 (Scores)。



从这个图中，可以看到我们把多维的评价体系降成了二维，此时数据点围绕着 (0,0) 分布，且可以视作分为四个象限。


有时，在 X 轴方向样本变化大，而在 Y 轴方向样本几乎无变化，但如果旋转坐标系，仍然可以进行 PCA 降维。正交变换后在新的坐标系下我们能更清楚看清数据的特点。



1.2 PCA 绘图

定义 1.5 (碎石图)

1. 横轴 (X 轴): 表示主成分的编号, 通常按主成分的重要性从第一个主成分 (PC1) 到最后一个主成分依次排列。
2. 纵轴 (Y 轴): 表示每个主成分所解释的方差 (或特征值), 通常表现为每个主成分对应的方差百分比, 或直接使用特征值。



定义 1.6 (载荷图)

载荷图显示每个特征对主成分的影响程度。

1. 点/箭头: 图上的每个点或箭头代表一个原始变量。这些点/箭头的坐标对应于该变量在不同主成分上的载荷值。
2. 载荷值: 载荷值的大小反映了原始变量与主成分之间的相关性。载荷值的取值范围通常在-1 到 1 之间。值越接近 1 或-1, 说明该变量与主成分的关系越强; 值越接近 0, 说明该变量与主成分的关系越弱。



方向和大小: 如果一个变量在某个主成分上的载荷值为正且较大, 说明该变量与这个

Tips

1. 主成分正相关, 即该变量值越大, 主成分值也越大。
2. 如果载荷值为负且绝对值较大, 说明该变量与主成分负相关, 即该变量值越大, 主成分值越小。
3. 如果载荷值接近 0, 说明该变量与主成分几乎没有相关性

变量之间的夹角:

1. 如果两个变量在载荷图上的夹角较小, 说明这两个变量之间有较强的正相关关系。
2. 如果夹角接近 90 度, 说明这两个变量之间几乎没有相关性。
3. 如果夹角接近 180 度, 说明这两个变量之间有较强的负相关关系。

主成分的组合解释: 通常我们通过观察前两个或前三个主成分的载荷图来解释数据。例如, PC1 和 PC2 组合可能解释了数据中的大部分方差, 通过载荷图我们可以看到哪些变量对这两个主成分贡献最大, 并尝试从业务角度解释这些主成分的实际意义。

定义 1.7 (得分图)


得分图是通过主成分分析 (PCA) 将高维数据投影到低维空间后, 得到的样本在主成分上的得分分布图。得分图可以帮助我们直观地观察样本在主成分空间中的分布情况, 识别潜在的聚类结构或异常点。

1. 横轴 (X 轴): 通常代表第一个主成分 (例如 PC1), 显示各个样本在这个主成分上的得分。
2. 纵轴 (Y 轴): 通常代表第二个主成分 (例如 PC2), 显示各个样本在这个主成分上的得分。
3. 点: 图上的每个点代表一个样本。这些点的坐标对应于该样本在不同主成分上的得分。



定义 1.8 (双标图)

双标图是得分图和载荷图的结合体，呈现在一个图上。



1.3 Kaiser 准则

定义 1.9 (Kaiser 准则)

Kaiser 准则的逻辑是：如果一个主成分的特征值大于 1，那么该主成分解释的方差比单个原始变量解释的方差更多。对于标准化数据，每个原始变量的方差为 1，因此，如果某个主成分的特征值小于 1，那么这个主成分解释的方差还不如一个原始变量，可能不值得保留。



```

1 def apply_kaiser_criterion(pca_model: PCA) -> int:
2     """应用 Kaiser 准则 (特征值 > 1) 来确定主成分数量"""
3     eigenvalues = pca_model.explained_variance_
4
5     print("各主成分的特征值 (Eigenvalues):")
6     for i, eig in enumerate(eigenvalues):
7         print(f"  PC{i + 1}: {eig:.4f}")
8
9     n_components = np.sum(eigenvalues > 1)
10    print(f"\n根据 Kaiser 准则 (特征值 > 1)，推荐保留的主成分数量为: {n_components}")
11    return n_components

```