

第 1 章 独立性检验

1. 当 $N \geq 40$ 且所有理论频数 $T \geq 5$ 时，用卡方检验即可，若此时计算出来的 p 值与规定的显著性水平（如 005）相近时，改用 Fisher 精准性检验。
2. 当 $n \geq 40$ 但存在某一个格子的理论频数 $T < 5$ ，此时用 Yates 检验，或用 Fisher 精准性检验。
3. 当 $n < 40$ ，或存在某一个格子的理论频数 $T < 5$ ，用 Fisher 精准性检验。

1.1 卡方检验

定义 1.1 (卡方检验)

卡方检验一般在总数据量 > 40 ，且每一个数据单元格中的期望频数 > 5 时使用。

💡 Tips

卡方检验统计量等于观测值与期望值之差的平方和除以期望值。在 $R \times C$ 列联表中，行列变量是无序的分类变量，则：

$$\chi^2 = N \left(\sum_{i=1}^R \sum_{j=1}^C \frac{A_{ij}^2}{\sum_{c=i}^C A_{ic} \sum_{r=1}^R A_{rj}} - 1 \right)$$

其中， A_{ij} 为实际频数， R 与 C 分别为行数与列数。 N 为频数综合。

此时，上式近似服从自由度为 $(r-1)(c-1)$ 的 χ^2 分布。

对给定的显著性水平 α ，检验的拒绝域为 $W = \{\chi^2 \geq \chi_{1-\alpha}^2((r-1)(c-1))\}$ 。



1.2 Fisher

定义 1.2 (Fisher 精准性检验)

Fisher 精准性检验是一种用于检验两个变量之间的相关关系的方法，与 K^2 检验有很多相似之处，但是它仅适用于小样本的校验，一般在 K^2 检验失效时（样本过小）使用。

Fisher 精准性检验通过计算精确的 p 值来判断两个分类变量之间的关联性，适用于 2×2 列联表。其公式如下所示：

	Men	Women	女性
Studying 学习	a	b	$a + b$
Non - studying 非学习	c	d	$c + d$
列总计	$a + c$	$b + d$	$a + b + c + d (= n)$

Fisher showed that conditional on the margins of the table, a is distributed as a hypergeometric distribution with $a + c$ draws from a population with $a + b$ successes and $c + d$ failures. The probability of obtaining such set of values is given by:

Fisher 证明，在表格边界条件下， a 服从超几何分布，其中 $a + c$ 取自于 $a + b$ 个成功案例和 $c + d$ 个失败案例的总体。获得此类值的概率如下：

$$p = \frac{\binom{a+b}{a} \binom{c+d}{c}}{\binom{n}{a+c}} = \frac{\binom{a+b}{b} \binom{c+d}{d}}{\binom{n}{b+d}} = \frac{(a+b)!(c+d)!(a+c)!(b+d)!}{a!b!c!d!n!}$$



表 1.1: 卡方检验与 Fisher 精准检验的对比

特性	卡方检验 (χ^2)	Fisher 精准检验
检验类型	近似检验	精准检验
适用条件	大样本数据。至少 80% 的单元格的期望频数大于 5	小样本数据。当卡方检验的条件不满足时使用

表 1.2: 新药疗效检验的列联表

组别	康复	未康复	总计
新药组	8	2	10
安慰剂组	3	7	10
总计	11	9	20

在表 1.2 中，我们展示了新药组与安慰剂组的康复情况对比。

```

1 import numpy as np
2 from scipy.stats import fisher_exact
3
4 # 2 x 2 列联表
5 # [8, 2, 10]
6 # [3, 7, 10]
7 # [11, 9, 20]
8 table = np.array([[8, 2], [3, 7]])
9 odds_ratio, p_fisher = fisher_exact(table) # fisher_exact 会返回: 优势比 (Odds Ratio), p值
10 print(f"优势比: {odds_ratio:.4f} P 值: {p_fisher:.4f}")
11
12 alpha = 0.05
13 if p_fisher < alpha:
14     print(f"在显著性水平 {alpha} 下, P-value ({p_fisher:.4f}) < {alpha}, 我们拒绝原假设。")
15     print("能够认为两个变量之间存在统计学关联性。")
16 else:
17     print(f"在显著性水平 {alpha} 下, P-value ({p_fisher:.4f}) >= {alpha}, 我们不能拒绝原假设。")
18     print("无法证明两个变量之间有关联。")

```

1.3 Yates 连续性校正

定义 1.3 (Yates 连续性校正)

当用卡方检验做独立性检验时，若任何一个字段的期望次数小于 5，会使“近似于卡方分配”的假设不可信，统计值会系统地偏高，导致过度地拒绝虚无假设。

在满足 Yates 校正的条件下，将每个观察值的离差减去 0.5 之后再平方，如下：

$$\chi_{\text{Yates}}^2 = \sum_{i=1}^R \sum_{j=1}^C \frac{(|A_{ij} - T_{ij}| - 0.5)^2}{T_{ij}} \sim \chi^2((R-1)(C-1))$$

校正目的：在卡方分布中，它是连续的概率分布，而我们从列联表中得到的频数是离散的。在小样本情况下，降低将离散型频数数据近似到连续性卡方统计量的过程中的误差。

A_{ij} : 代表在 $R \times C$ 列联表中，第 i 行、第 j 列单元格中的观测频数 (Observed Frequency)，即该单元格内的实际观察计数值。

T_{ij} : 代表在原假设 H_0 (即行列变量相互独立) 成立的条件下，第 i 行、第 j 列单元格中的理论频数 (Theoretical Frequency)，也常称为期望频数 (Expected Frequency)。



Yates 连续性检验只需要在原来的卡方检验代码基础上添加校正即可。

```

1 print("--- 卡方检验的结果 (Yates 校正) ---")
2 chi2_yates, p_yates, dof, expected_yates = chi2_contingency(obs_data, correction=True)
3
4 print("\n--- 标准皮尔逊卡方检验的结果 (无校正) ---")
5 chi2_pearson, p_pearson, dof, expected_pearson = chi2_contingency(obs_data, correction=False)

```

第 2 章 聚类分析

2.1 K-means 聚类

定义 2.1 (聚类分析)

聚类分析是一种将数据集划分为多个簇 (Cluster) 的技术, 使得同一簇内的数据点相似度较高, 而不同簇之间的数据点相似度较低。聚类分析常用于探索性数据分析、图像处理、市场细分等领域。



定义 2.2 (无监督问题与有监督问题)

当我们手里对一组数据没有标签时, 称为无监督问题。事先无法对样本进行准确的判定, 需要建立和总结一定的规则模式后再定性的, 属于无监督学习。相反, 样本一开始就拥有“目标”标签的话, 我们所进行的从特征到目标的建模, 则是有监督的学习。



定义 2.3 (K-Means 算法)

K-Means 算法预先指定初始聚类数以及初始化聚类中心, 按照样本之间的距离大小, 把样本集根据数据对象与聚类中心之间的相似度划分为类簇, 不断更新聚类中心的位置, 不断降低类簇的误差平方和 (Sum of Squared Error, SSE), 当 SSE 不再变化或目标函数收敛时, 聚类结束, 得到最终结果。

1. 先从数据集中随机选取 K 个初始聚类中心 $C_i (1 \leq i \leq k)$, 计算其余数据对象与聚类中心 C_i 的欧氏距离, 找出离目标数据对象最近的聚类中心 C_i , 并将数据对象分配到聚类中心 C_i 所对应的簇中;
2. 接着计算每个簇中数据对象的平均值, 将该值当作新的聚类中心, 进行下一次迭代, 直到聚类中心不再变化或达到最大的迭代次数时停止。

空间中数据对象与聚类中心间的欧氏距离计算公式为:

$$d(X, C_i) = \sqrt{\sum_{j=1}^m (X_j - C_{ij})^2}$$

其中, X 为数据对象; C_i 为第 i 个聚类中心; m 为数据对象的维度; $X_j C_{ij}$ 为 X 和 C_i 的第 j 个属性值。

整个数据集的 SSE 计算公式为:

$$SSE = \sum_{i=1}^k \sum_{X \in C_i} |d(X, C_i)|^2$$

其中, SSE 的大小表示聚类结果的好坏; k 为簇的个数。

