

第 1 章 相关性检验

1.1 Pearson

定义 1.1 (Pearson)

Pearson 相关性检验是一种用于检验两个变量之间线性相关关系的方法。它通过计算 **Pearson** 相关系数来量化这种关系的强度和方向。

定理 1.1 (Pearson 相关系数)

又称相关系数或线性相关系数，一般用字母 r 表示，定义式：

$$r(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}[X] \text{Var}[Y]}}$$

推论 1.1 (系数特性)

特性：两个变量的位置和尺度的变化不会引起该系数的改变，即把 X 移动到 $a + bX$ 和把 Y 移动到 $c + dY$ （其中 a 、 b 、 c 、 d 为常数）并不会改变相关系数（该结论在总体和样本皮尔逊相关系数中都成立）。

Pearson 的计算基础是基于数据值的协方差和标准差。

当数据满足正态分布、线性变化时，使用 Pearson，数据还不能有太多异常值，例如身高和体重之间的探究。

💡 Tips

1.2 Spearman 相关系数

定义 1.2 (Spearman 相关系数)

又称斯皮尔曼等级相关系数，常用希腊字母 ρ 表示。其利用单调方程评价两个统计变量的相关性。如果数据中没有重复值，并且当两个变量完全单调相关时，斯皮尔曼相关系数则为 +1 或 -1。定义式：

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \in [-1, 1]$$

结论：无参数的等级相关系数，亦即其值与两个相关变量的具体值无关，而仅仅与其值之间的大小关系有关。 d_i 表示两个变量分别排序后成对的变量位置差， n 表示 n 个样本，减少异常值的影响。

Spearman 的计算基础是基于数据值的排名（秩）。

定理 1.2

假设我们有两个随机变量 X 和 Y 的 n 个观测值。我们首先将这两个变量的所有值分别排序为 X_r 和 Y_r 。Spearman 等级相关系数表示为 r_s ，计算公式如下：

$$r_s = \rho_{X_r, Y_r} = \frac{\text{COV}(X_r, Y_r)}{\text{STD}(X_r) \text{STD}(Y_r)} = \frac{n \sum_{x_r \in X_r, y_r \in Y_r} x_r y_r - \sum_{x_r \in X_r} x_r \sum_{y_r \in Y_r} y_r}{\sqrt{\left(n \sum_{x_r \in X_r} x_r^2 - \left(\sum_{x_r \in X_r} x_r\right)^2\right)} \sqrt{\left(n \sum_{y_r \in Y_r} y_r^2 - \left(\sum_{y_r \in Y_r} y_r\right)^2\right)}}$$

其中， $\text{COV}()$ 表示协方差， $\text{STD}()$ 表示标准差。

数据不满足正态分布的假设，存在异常值，并且变量是有序分类变量（满意度评分等），关系可能是非线性的，例如广告投入与销售额之间的关系（有边际效应递减）。

💡 Tips

推论 1.2 (判别)

对于强相关性的样本，统计量的值较高（趋近于 1），对于具有强负序相关性的样本，该统计量的值较低（趋近于 -1），对于具有弱序相关性的样本，统计量接近于 0。

Spearman 不关心数值大小，只关心排序。我们先对数据进行排名：

⚠ Warning

- 工作年限的排名: [1,2,3,4,5,6]

- 月薪的排名: [1,2,3,4,5,6]

可以看到，两个变量的排名是完全一致的 (1,2,3,4,5,6)，因此它们构成了一个完美的“单调递增”关系。

```
1 import pandas as pd
2 from scipy.stats import spearmanr
3
4 df = pd.DataFrame({'student': ['A', 'B', 'C', 'D', 'E', 'F', 'G', 'H', 'I', 'J'],
5                     'math': [70, 78, 90, 87, 84, 86, 91, 74, 83, 85],
6                     'science': [90, 94, 79, 86, 84, 83, 88, 92, 76, 75]})
7
8 rho, p = spearmanr(df['math'], df['science'])
9 print(f"Rho: {rho:.4f}, p: {p:.4f}")
10
11 # 从输出中可以看到，Math 成绩和 Science 成绩之间存在负相关性
12 # 但是相关性的 p < 0.05，说明这种相关性并不显著。
13 # 这可能是因为样本量较小，或者数据中存在异常值等原因导致的。
```

1.2.1 Spearman 相关系数矩阵

定义 1.3 (相关系数矩阵)

对于 n 个随机变量，它返回一个 $n \times n$ 方阵 R 。 $R(i, j)$ 表示随机变量 i 和 j 之间的 Spearman 秩相关系数。由于一个变量与其自身之间的相关系数为 1，因此所有对角线元素 (i, i) 都等于 1。简而言之：

$$R(i, j) = \begin{cases} r_{i,j} & \text{if } i \neq j \\ 1 & \text{otherwise} \end{cases}$$



当有一个包含多个数值变量的数据集时，若要知道每一对变量之间的 Spearman 相关性，就需要用 Spearman 相关系数矩阵。

```
1 np.random.seed(42)
2 data = {
3     '学习时长': np.arange(1, 11), # 线性增长: 1, 2, ..., 10
4     '考试分数': [10, 15, 20, 35, 50, 65, 75, 80, 82, 83], # 非线性增长 (前期快, 后期慢)
5     '分心次数': [9, 10, 8, 7, 6, 5, 3, 4, 2, 1], # 负相关
6     '无关噪音': np.random.rand(10) * 100 # 一个完全随机的列
7 }
8 df = pd.DataFrame(data)
9
10 print(df)
11 spearman_corr_matrix = df.corr(method='spearman')
12 print(spearman_corr_matrix)
13
14 plt.figure(figsize=(8, 6)) # 设置画布大小
15 heatmap = sns.heatmap(
16     spearman_corr_matrix,
17     annot=True,           # 在格子里显示数字
18     cmap='coolwarm',     # 设置配色方案, coolwarm 很适合相关性 (红正蓝负)
19     fmt='.2f'             # 格式化数字, 保留两位小数
20 )
21 plt.title('Spearman 相关系数热力图', fontsize=16)
22 plt.show()
```