

第 1 章 缺失值填补

1.1 简单填补

定义 1.1 (简单填充)

简单填充是一种单变量 (Univariate) 填充策略，它使用数据集中单个特征列的统计量 (如均值、中位数或众数) 来替换该列中的所有缺失值。这种方法不考虑特征之间的关系。

在 `scikit-learn` 中，这通常通过 `SimpleImputer` 类实现。常见的策略包括：

1.

定义 1.2 (均值填充)

使用该特征所有观测值的算术平均数来填充缺失值。对于特征向量 x_j ，其填充值 $\hat{x}_{ij}$ (其中 i 是缺失值的行索引) 计算如下：

$$\hat{x}_{ij} = \bar{x}_j = \frac{1}{|\text{obs}(j)|} \sum_{k \in \text{obs}(j)} x_{kj}$$

其中 $\text{obs}(j)$ 代表特征 j 中所有非缺失值的索引集合。

2.

定义 1.3 (中位数填充)

使用该特征所有观测值的中位数进行填充。当中位数比均值更能抵抗异常值的影响时，这是一种更稳健的选择。

3.

定义 1.4 (常数填充)

使用一个固定的常数值 (例如 0) 来填充所有缺失值。

简单填充计算速度快，易于实现。但它的主要缺点是会扭曲数据的原始分布，并低估方差。更重要的是，它完全忽略了特征之间的相关性，可能导致后续模型训练时信息的丢失。

💡 Tips

1.2 KNN 填补

定义 1.5 (KNN 插值)

KNN 插值是一种基于邻居的插值方法。对于每个缺失值，找出与其最相似的 K 个样本，然后用这 K 个样本的特征均值来填充缺失值。`KNNImputer` 通过欧几里德距离矩阵寻找最近邻。

- 优点：能够利用数据的局部特性进行填充。
- 缺点：计算量较大， K 值的选择对结果影响较大。

💡 Tips

每个样本的缺失值，都是从其他训练集中找到最近邻的平均值估算的，如果两个都不缺失的特征都相近，那么两个样本就相近。

在找到距离待预测样本 x 最近的 k 个邻居 (记为集合 $N_k(x)$) 之后，我们需要根据这些邻居的信息来做出决策。

定义 1.6 (KNN 分类决策)

对于分类问题，决策规则通常是“多数表决策”。即预测样本 x 的类别 $\hat{y}$ 为其 k 个最近邻居中出现次数最多的类别。

$$\hat{y} = \arg \max_{c \in \mathcal{Y}} \sum_{(x_i, y_i) \in N_k(x)} I(y_i = c)$$

其中：

- $\mathcal{Y}$ 是所有可能的类别标签的集合。
- c 是其中一个类别。
- $I(\cdot)$ 是指示函数，当条件成立时为 1，否则为 0。
- $\arg \max$ 表示取能让后面表达式值最大的那个类别 c 。

定义 1.7 (KNN 回归决策)

对于回归问题，决策规则通常是“平均法”。即预测样本 x 的值为其 k 个最近邻居的真实值的平均数。

$$\hat{y} = \frac{1}{k} \sum_{(x_i, y_i) \in N_k(x)} y_i$$

有时也会使用“加权平均法”，即根据距离的远近为邻居分配不同的权重（例如，距离越近，权重越大），然后进行加权平均。若权重 $w_i = 1/d(x, x_i)$ ，则公式为：

$$\hat{y} = \frac{\sum_{(x_i, y_i) \in N_k(x)} w_i y_i}{\sum_{(x_i, y_i) \in N_k(x)} w_i}$$



```

1 from sklearn.impute import KNNImputer
2 import numpy as np
3
4 X = [[1, 2, np.nan], [3, 4, 3], [np.nan, 6, 5], [8, 8, 7]]
5 np.array(X)
6 Out[16]:
7 array([[ 1.,  2., nan],
8        [ 3.,  4.,  3.],
9        [nan,  6.,  5.],
10       [ 8.,  8.,  7.]])
11
12 imputer = KNNImputer(n_neighbors=2)
13 imputer.fit_transform(X)
14 Out[14]:
15 array([[1. , 2. , 4. ],
16       [3. , 4. , 3. ],
17       [5.5, 6. , 5. ],
18       [8. , 8. , 7. ]])

```

1.3 随机森林填补

定义 1.8 (随机森林插值)

具体做法是为每个缺失值特征训练一个随机森林模型，通过该模型对缺失值进行预测。



- 优点：能够处理非线性关系的特征，预测准确性较高。
- 缺点：需要额外的训练过程，可能增加计算复杂度。

Tips

1.3.1 数据预处理阶段的随机森林填充

此时我们的目标主要是修复数据，此时没有 `Y_full` 这个值，我们的目的是修复数据。

1.3.2 模型训练阶段

如果我们拥有一个特征表 X 和目标 Y ，我们的目标是预测 Y ，此时 Y 是标准答案。