


第 1 章 聚类分析

1.1 DBSCAN-密度聚类



定义 1.1 (DBSCAN-密度聚类)

密度聚类 (DBSCAN) 是一种无需事先指定聚类数量的聚类算法。通过不断扩展核心点的邻域, 将所有密度相连的核心点划分为同一个聚类。对于边界点, 如果它属于某个核心点的邻域内, 但本身不是核心点, 则被划分到该核心点所属的聚类中。最终, 不属于任何核心点邻域的样本点被标记为噪声。

DBSCAN 基于 “密度” 的概念来定义聚类。简单来说, 聚类是由密集区域中的点组成的, 稀疏区域则被视为噪声。三个关键定义:

1. 核心点: 如果一个点周围在指定的半径 (称为 ϵ) 内, 至少有一定数量 (minPts) 的点, 那么这个点就是核心点。核心点是聚类的 “中心”。其中, 邻域为:

$$N_{\epsilon}(p) = \{q \in D \mid d(p, q) \leq \epsilon\}$$

p is a Core Point if $|N_{\epsilon}(p)| \geq \text{MinPts}$

2. 边界点: 如果一个点在核心点的邻域内, 但自身不是核心点, 那么这个点是边界点。边界点靠近核心点, 但不是密集区域的中心。

q is a Border Point if $|N_{\epsilon}(q)| < \text{MinPts}$ and $\exists p, (p \text{ is a Core Point and } q \in N_{\epsilon}(p))$

3. 噪声点: 如果一个点既不是核心点, 也不是边界点, 那么它被视为噪声点, 属于离群点。



1. Eps 和 MinPts 是全局参数, 难以处理不同密度的簇。
2. 该模型对参数很敏感, 需要不断调整参数达到较好的聚类效果;
3. 该模型在高维数据中表现不佳, 可能面临 “维度灾难”。

Warning

<https://www.bbbdata.com/text/344>

Tips

1.1.1 OPTICS 算法

为了解决 DBSCAN 的全局参数的局限性, 可以解决参数设置困难的问题。此时引入了两个核心概念:

定义 1.2 (核心距离)

对于点 p , 若其邻域内有足够点 ($\geq \text{MinPts}$), 则核心距离为 p 到其第 MinPts 近邻的距离。若邻域内不足 MinPts 个点, 则核心距离未定义 (无穷大)。



定义 1.3 (可达距离)

对于点 A 和 B , B 相对于 A 的可达距离是 A 的核心距离和 A 到 B 的欧氏距离之间的较大值。

$$\text{reachability_distance}(A, B) = \max(\text{core_distance}(A), \text{distance}(A, B))$$

直观理解: 可达距离衡量了从一个点到另一个点 “被密度连接” 的难易程度。



OPTICS 通过类似 DBSCAN 的过程对数据进行排序，优先处理核心距离小的点（更密集区域）。输出一个“可达距离图”，通过观察“山谷”（低可达距离区域）识别簇。

但是，复杂性很高，簇的提取也很困难，需要手动观察可达距离图，还需要指定 `minPts`，而且可达距离是不对称的。

1.1.2 HDBSCAN 层次化的密度聚类

定义 1.4 (HDBSCAN)

引入了相对密度的概念，可以动态地通过互达距离，定义点之间的密度连接关系，更稳健。

密度层次化聚类：

- 通过跟踪密度逐步降低的过程，生成密度分层树。
- 树的叶子节点代表高密度簇，根节点代表整个数据集。

自动化簇提取：提供自动化的簇提取方法，通过稳定性指标评估簇的持久性。

解决的问题：

- 密度差异问题：同一数据集中可能存在密度差异很大的聚类，简单使用原始距离可能导致低密度簇被忽略。
- 噪声数据识别问题：噪声点通常分布稀疏，与聚类距离较远，使用原始距离可能难以区分。

💡 Tips

所有具体算法的讲解在：<https://www.bilibili.com/video/BV1ktJizBEU6>

💡 Tips

1.1.3 快速多核低维欧几里得空间的 HDBSCAN 算法

定义 1.5

`fast_hdbscan` 库提供了 HDBSCAN 聚类算法的简单实现，该算法专为在多核机器上处理低维数据（2 维到 20 维左右）而设计，以实现高性能。该算法并行运行，可以有效利用任意数量的内核来解决问题。因此，它非常适合大型 SMP 系统，甚至是现代多核笔记本电脑。

https://github.com/TutteInstitute/fast_hdbscan/

💡 Tips

1.1.4 采用 DBSCAN 对高维向量采用余弦相似度聚类

定义 1.6

对高维数据（例如来自语言模型的嵌入）进行聚类面临着独特的挑战。与需要预先指定聚类数量的 K-Means 算法不同，此代码库提供了一种使用 DBSCAN 算法的高级解决方案——这是一种适应性更强、洞察力更强的方法，尤其适用于大型复杂数据集。

<https://github.com/yigitkonur/hdbscan-embeddings-clustering>

💡 Tips